

CLASSIFICAÇÃO DA TOXOPLASMOSE OCULAR EM IMAGENS DE FUNDO DE RETINA UTILIZANDO CARACTERÍSTICAS RADIÔMICAS

Gustavo Vaz Teixeira¹, Alessandra Martins Coelho¹, Matheus de Freitas Oliveira Baffa²

¹Instituto Federal de Educação, Ciência e Tecnologia do Sudeste de Minas Gerais, Rio Pomba, Brasil (guteixeira2001@gmail.com)

²Universidade de São Paulo, Ribeirão Preto, Brasil

Resumo: A toxoplasmose ocular, provocada pelo parasita *Toxoplasma gondii*, pode ocasionar lesões retinianas e cegueira. Diante disso, esta pesquisa propõe um método de classificação automatizada da doença em imagens de fundo de olho, por meio de características radiômicas. Foram utilizadas 512 imagens e algoritmos de *machine learning* e *deep learning*. Almeja-se acurácia superior a 90%, contribuindo para o apoio diagnóstico oftalmológico.

Palavras-chave: Toxoplasmose ocular; classificação; aprendizado de máquina; visão computacional

INTRODUÇÃO

A toxoplasmose é uma doença infecciosa, que afeta 33% da população mundial e é causada pelo parasita *Toxoplasma gondii*. Esse parasita está presente em todos os continentes, embora sua taxa de infecção seja maior em países tropicais, devido a maiores temperaturas e humidades (Nogueira; Liverani, 2014). Surto de toxoplasmose em humanos já foram previamente relatados por autores como Bonametti et al. (1997) e Dias e Freire (2005), associando-os diretamente com a ingestão de verduras e água contaminadas e também de carne mal cozida. Condições precárias de saneamento básico também estão associadas com a transmissão do parasita (Santos; Conceição, 2018). Segundo dados do Instituto Adolfo Lutz, a toxoplasmose afeta um a cada três brasileiros e, entre 2019 e 2022, foram registrados 40 mil casos e, a Organização Mundial da Saúde estima que cerca de 420 mil pessoas morrem por ano por causa da infecção (Tavares, 2024). Uma forma adicional de transmissão para humanos é pelo contato direto com fezes infectadas de felinos. Na figura 1, está ilustrado o parasita *Toxoplasma gondii*, na cor roxa e no formato de uma banana.




Figura 1. O parasita *Toxoplasma gondii*.

Diferentes órgãos podem ser afetados pela toxoplasmose, como o pulmão, o cérebro, os olhos, entre outros. Quando a toxoplasmose causa problemas nos olhos, a doença recebe o nome de toxoplasmose ocular. No caso da toxoplasmose congênita, ela pode se manifestar de duas maneiras: uveíte, com mínimas chances de sequelas se tratada corretamente, e a coriorretinite, uma inflamação na retina que deixa cicatrizes que, dependendo do seu tamanho, pode ocorrer uma diminuição na visão. Ressalta-se que não é possível reverter os danos causados pelas cicatrizes (Hospital de Olhos de Sergipe, 2017) e, caso não sejam tratadas corretamente, podem levar à cegueira (Shinzato, 2016).

O exame oftalmológico que detecta a toxoplasmose ocular é o exame de fundo de olho (Nogueira; Liverani, 2014; Hospital de Olhos de Sergipe, 2017). A classificação da doença é feita com base na identificação das lesões presentes na retina, que podem ser de diferentes formatos e ocorrer em qualquer parte da retina. Essa variabilidade da manifestação da doença destaca a complexidade do diagnóstico e a importância de estudar a aplicação de métodos avançados da Ciência da Computação, como visão computacional, aprendizado de máquina e processamento de imagens, para auxiliar médicos oftalmologistas na identificação e tratamento eficaz da doença, evitando suas complicações.

A área de aprendizado de máquina, parte da inteligência artificial, concentra-se em ensinar computadores a lidar com problemas que envolvem



um grande número de dados de forma eficiente, sem serem necessariamente programados. Para enfrentar diferentes desafios que envolvem grandes volumes de dados, essa área utiliza uma grande variedade de algoritmos, ressalta-se que não há um algoritmo que resolva todos os problemas, uma vez que esse fato depende do tipo de problema que está sendo estudado, do número de variáveis, entre outros fatores (Mahesh, 2018). O aprendizado de máquina proporcionou avanços significativos na área de visão computacional, uma área que tem como objetivo adaptar os computadores para reconhecer padrões, como pessoas e objetos (Microsoft, 2023). Frequentemente, métodos de visão computacional são combinados com técnicas focadas em transformar imagens em outras imagens. Essas transformações incluem melhorias na qualidade, remoção de ruído, segmentação e detecção de características específicas e objetos. Em relação às imagens de fundo de olho, essas técnicas incluem extração do canal verde ou escala de cinza, equalização do histograma ou equalização adaptativa do histograma limitada por contraste, entre outras.

Na oftalmologia, esses métodos proporcionaram avanços significativos na detecção automática de doenças, como o glaucoma (Kim; Cho; Oh, 2017), a retinopatia diabética (Baffa et al., 202) e até mesmo na toxoplasmose ocular (Alam et al., 2023). A extração de características também contribuiu para avanços para a detecção precoce de diversas doenças, podendo ser essenciais para identificar padrões sutis em imagens de fundo de olho, complementando a avaliação clínica realizada por oftalmologistas.

Um tipo de características que está em ascensão no contexto de imagens médicas são as características radiômicas. Essas características são focadas em atributos como cor, forma e textura, com foco em encontrar possíveis associações entre informações quantitativas e qualitativas. As informações quantitativas são descritores extraídos de imagem por softwares, necessitando de uma imagem e uma máscara limitando a área de interesse como entrada, e permitem selecionar os melhores parâmetros para garantir uma saída robusta e confiável. As características qualitativas são utilizadas em radiologia para descrever lesões de imagens clínicas e dados médicos. Essas informações podem ser empregadas para apoiar decisões baseadas em evidências. Embora inicialmente fossem voltadas apenas para a radiologia, é possível encontrar esse tipo de características em diferentes tipos de imagens médicas, como na oftalmologia. Estudos como Baffa et al. (2022) tem demonstrado que a aplicação de técnicas de extração de características radiômicas em imagens geradas por exames de fundo de olho podem contribuir para a detecção precisa de lesões associadas a doenças como a retinopatia diabética.

Os dados das radiômicas oferecem vantagens, como minerabilidade, o qual pode descobrir padrões desconhecidos de evolução de doenças. As radiômicas também oferecem vantagens em comparação com os métodos baseados em arquiteturas de redes neurais convolucionais (CNN), por serem computacionalmente menos pesadas e mais rápidas. Os dados obtidos pela extração de características radiômicas podem ser usados como parâmetros para treinar algoritmos de aprendizado de máquina.

Com isso em mente, neste artigo foi investigado técnicas computacionais para auxiliar no diagnóstico da toxoplasmose ocular. O método proposto utiliza as características radiômicas para fornecer uma descrição de conteúdos de imagens, facilitando a detecção de padrões através de algoritmos como *support vector machine* (SVM), *decision tree* (DT), *random forest* (RF), *stochastic gradient descent* (SGD), *adaptive boosting* (Adaboost), *extreme gradient boosting* (XGBoost), *multilayer perceptron* (MLP), e também uma rede neural totalmente conectada (FCNN). Os resultados obtidos pelos algoritmos foram comparados com métodos presentes na literatura, que empregaram modelos baseados em CNN (ResNet50, ResNet18, VGG16, etc.). A contribuição principal deste artigo é o desenvolvimento de um novo método de classificação da toxoplasmose ocular, aproveitando a extração de características radiômicas em imagens de fundo de olho diagnosticadas com toxoplasmose ocular.

MATERIAL E MÉTODOS

Como base de dados, foram utilizadas as imagens de fundo de olho para diagnóstico da toxoplasmose ocular, o qual está disponível publicamente para fins de pesquisa (REF do BD). Essa base de dados consiste em imagens de fundo de olho de pacientes diagnosticados com toxoplasmose ocular. Essas imagens foram obtidas de dois hospitais diferentes, o *Hospital de Clínicas* (212 imagens, coletadas em 12 de dezembro de 2017) e do *Hospital General Pediatrico Acosta Ñu* (69 imagens, mas sem informações sobre a data de aquisição), ambos localizados em Asunción, no Paraguai.

A base de dados original continha um número variável de imagens saudáveis e doentes, sendo a maioria diagnosticadas com toxoplasmose ocular. Para diminuir os potenciais problemas durante a fase de reconhecimento de padrões, foram importadas imagens de fundo de uma outra base de dados, conhecida como *Fundus Image Registration Dataset* (FIRE), para deixar o número igual de classes saudáveis e doentes. Como resultado, a base de dados balanceada consistia de 562 imagens, com 281 exemplos de cada classe. Tendo em mente que as imagens neste estudo foram recuperadas de

diferentes hospitais, elas possuem diferenças no processo de aquisição, incluindo variação de posição e luminosidade. Na figura 2, está demonstrado uma comparação visual dessa variabilidade, na qual 2(a) é uma imagem do *Hospital de Clínicas* e 2(b) é uma imagem do *Hospital General Pediátrico Acosta Ñu*.




Figura 2. Exemplo de imagens de fundo de olho dos hospitais.

Fatores humanos, como a idade e cor da pele do paciente também podem causar variações nas imagens de fundo de olho. Por isso, foi proposto uma padronização da base de dados para manter a consistência entre as imagens e destacar a visibilidade das áreas com a ferida da toxoplasmose ocular.

A etapa de pré-processamento que foi utilizada neste estudo foi baseada em pesquisas prévias, seguindo os seguintes passos: (i) redimensionamento das imagens, (ii) separar o canal verde, (iii) equalização do histograma, e (iv) isolar a negativa. O fluxograma do pré-processamento está ilustrado na figura 3.




Figura 3. Fluxograma da etapa de pré-processamento.

A variância nos métodos de aquisição entre os diferentes hospitais resultou em uma heterogeneidade na altura e largura das imagens, nas quais as imagens do *Hospital de Clínicas* estavam no formato 2124x2056 pixels, enquanto as imagens do *Hospital General Pediátrico Acosta Ñu* estavam no formato 1563x1152 pixels, e as imagens do projeto FIRE estavam no formato 1140x960 pixels. Para resolver esse problema, todas as imagens foram redimensionadas para o formato 512x512 pixels.

Após analisar a composição da imagem e explorar espaços de cores alternativos para representar imagens de fundo de olho, foi notável que o canal verde oferecia informações mais detalhadas sobre as estruturas internas do olho, incluindo vasos sanguíneos, estruturas da retina e anormalidades como feridas e cicatrizes associadas à toxoplasmose ocular. Consequentemente, isso reduziu a influência da cor nas imagens. A etapa subsequente em nosso pré-processamento envolve o isolamento desse canal para análises mais aprofundadas. Na figura 4, está demonstrado a extração do canal verde das imagens de fundo de olho 4(c), melhorando a visibilidade das anomalias, em comparação com a escala de cinza 4(b).




Figura 4. Imagem original (a), imagem original na escala de cinza (b) e imagem original com o canal verde isolado (c)

Após a aplicação da extração do canal verde, foi aplicada a equalização do histograma nas imagens, que resultou em algumas áreas excessivamente escura ou clara, reduzindo a quantidade de informações na imagem. Para resolver esse problema, nós implementamos a técnica equalização do histograma adaptativo limitado pelo contraste (do inglês, *contrast-limited adaptive histogram equalization* - CLAHE), para padronizar a distribuição de cores entre os exemplos. Na figura 5, pode-se observar uma comparação entre a aplicação da CLAHE 5(c), com a equalização do histograma 5(b) e a imagem com o canal verde extraído 5(a).




Figura 5. Imagem com o canal verde extraído (a), imagem com a equalização do histograma (b) e imagem com a aplicação da CLAHE (c).

Posteriormente, a negativa das imagens foi extraída para destacar as anomalias como manchas escuras,

cercadas por bordas nítidas. Na figura 6, tem-se um exemplo de todas as estampas do pré-processamento.




Figura 6. Todas as etapas do pré-processamento das imagens.

Após a etapa de pré-processamento, foram extraídas 220 características das imagens, das quais 94 eram da biblioteca *Pyradiomics* e as restantes da biblioteca *Mahotas*. As características da *Pyradiomics* incluem 19 de Estatísticas de Primeira Ordem, 24 da Matriz de Coocorrência de Níveis de Cinza (GLCM), 16 da Matriz de Comprimento de Corrida de Níveis de Cinza (GLRLM), 16 da Matriz de Zona de Tamanho de Níveis de Cinza (GLSZM), cinco da Matriz de Diferença de Tons de Cinza Vizinhos e 14 da Matriz de Dependência de Níveis de Cinza (GLDM). Além disso, o framework *Mahotas* extraiu 126 características, incluindo 36 Padrões Binários Locais (LBP), 36 Momentos de Zernike e 54 características de Estatísticas de Adjacência por Limiar (TAS). Essa combinação resultou em um vetor de características abrangente composto por 220 elementos.

Tabela 1. Lista das características extraídas usando a *Mahotas* e *Pyradiomics* para representar o conteúdo das imagens.

Grupo de Característica	Número de características
Estatísticas de Primeira Ordem (<i>Pyradiomics</i>)	19
Matriz de Coocorrência de Níveis de Cinza (<i>Pyradiomics</i>)	24
Matriz de Comprimento de Corrida de Níveis de Cinza (<i>Pyradiomics</i>)	16
Matriz de Zona de Tamanho de Níveis de Cinza (<i>Pyradiomics</i>)	16
Matriz de Diferença de Tons de Cinza Vizinhos (<i>Pyradiomics</i>)	5
Matriz de Dependência de Níveis de Cinza (<i>Pyradiomics</i>)	14
Padrões Binários Locais (<i>Mahotas</i>)	36
Momentos de Zernike (<i>Mahotas</i>)	36
Estatísticas de Adjacência por Limiar (<i>Mahotas</i>)	54

Tanto a *Mahotas* quanto a *Pyradiomics* precisam de uma imagem e uma máscara para delimitar a região de interesse. Essas máscaras especificam a área para a extração de características. Considerando que as lesões da toxoplasmose ocular podem ocorrer em qualquer parte da retina, a região de interesse foi definida com a retina. Na figura 7, está ilustrado um exemplo de imagem pré-processada 7(a) e sua máscara 7(b).




Figura 7. Uma imagem pré-processada (a) e sua máscara (b).

Em sequência a extração de características, o algoritmo *SelectKBest* foi utilizado para ranquear as 100 características mais impactantes. Esse passo reduziu significativamente o número de características, de 220 para 100, sem simplificar demais e, potencialmente perder informação crucial sobre as relações necessárias para o modelo de classificação. Por fim, os dados foram normalizados usando o método *MinMax*, padronizando os valores das características entre 0 e 1. Esse processo de normalização mitiga a influência de grandes valores durante a fase de treino.

Para detectar padrões nas características extraídas, é necessário um algoritmo de aprendizado de máquina capaz de criar um modelo de classificação complexo. Assim, foi estabelecido um *benchmark* composto por algoritmos tradicionais de aprendizado de máquina, incluindo a SVM, DT, RF, SGD, AdaBoost, XGBoost e o MLP, e também uma variante da *Keras*, chamada FCNN. A maioria desses algoritmos foi implementada usando o *Scikit-learn*, na linguagem de programação *Python*. O vetor de características, resultado da fase de extração de características radiômicas foi utilizado como parâmetro de entrada para todos esses algoritmos.

RESULTADOS E DISCUSSÃO

O protocolo de experimento emprega o método de validação cruzada *K-Fold*, no qual $k = 10$. Isso significa que a base de dados foi dividida em dez partições. Durante cada iteração, os modelos são treinados em nove partições e validados em um, com partições selecionadas aleatoriamente até que todas sejam utilizadas, no final, o erro médio é calculado na conclusão do processo.

Os modelos foram avaliados utilizando as métricas tradicionais de aprendizado de máquina, acurácia (ACC), área sob a curva (do inglês, *area under the curve* - AUC), *F1-Score*, *recall* e precisão (PRE).

Na tabela 2, são listados os resultados obtidos pelos algoritmos utilizados com a extração de características da *Pyradiomics* e *Mahotas*. Todos os algoritmos obtiveram performance excedendo 90% em todas as métricas. Analisando as métricas separadamente, o SVM com *kernel* polinomial e o MLP obtiveram a melhor performance de 96% cada. O SVM polinomial obteve a melhor performance na métrica *F1-Score* e *recall*, com uma pontuação de 96% em cada. Para a métrica de precisão, o MLP obteve 97% de pontuação, sendo a melhor entre os algoritmos. Para a métrica AUC, o SVM polinomial, o SVM linear, o SVM RBF e a MLP empataram, com uma performance de 99%.

Tabela 2. Média da performance dos classificadores.

Class.	ACC	F1	Pre	Rec	AUC
SVM poli.	96%	96%	96%	96%	99%
SVM lin.	95%	95%	96%	94%	99%
SVM RBF	94%	94%	95%	94%	99%
DT	92%	92%	93%	92%	92%
RF	94%	94%	94%	95%	98%
SGD	94%	93%	96%	92%	98%
Adaboost	92%	92%	92%	92	97%
XGBoost	93%	93%	93%	95%	98%
MLP	96%	95%	97%	95%	99%
FCNN	93%	93%	95%	92%	93%

A disponibilidade de uma base de dados pública contendo imagens da toxoplasmose ocular foi crucial no desenvolvimento da presente pesquisa, uma vez que o pré-requisito para se trabalhar com aprendizado de máquina é a disponibilidade de dados.

Após a busca por trabalhos disponíveis na literatura, notou-se que as pesquisas que trabalharam com a toxoplasmose ocular utilizaram arquiteturas de CNNs, e foi encontrada uma lacuna, na qual não foi encontrado nenhuma pesquisa que utilizou a abordagem baseada em extração de características radiômicas e algoritmos de aprendizado de máquina na detecção automática da toxoplasmose ocular.

Na tabela 3, estão tabulados os resultados obtidos pelas arquiteturas de CNN, utilizadas pelos trabalhos da literatura. Observa-se que, os resultados obtidos pela implementação de características radiômicas foi equivalente aos resultados obtidos pelas arquiteturas de CNN.

Tabela 3. Resultados obtidos pelos trabalhos disponíveis na literatura.

Class.	ACC	F1	Pre	Rec	AUC
VGG16 (Alam et al. 2023)	97%	97%	97%	97%	-
DenseNet (Alam et al. 2023)	98%	98%	98%	97%	-
ResNet50 (Alam et al. 2023)	97%	97%	97%	97%	-
Inception V3 (Alam et al., 2023)	98%	98%	97%	99%	-
Mobile Net (Alam et al., 2023)	98%	98%	99%	98%	-
Vanilla CNN (Parra et al., 2021)	75%	-	-	-	-
ResNet18 (Parra et al., 2021)	96%	-	-	-	-
VGG16 (Parra et al., 2021)	93%	-	-	-	-
ResNet18 - SGD (Parra et al., 2021)	93%	-	-	-	-
ResNet18 - SGD m. (Parra et al., 2021)	93%	-	-	-	-
ResNet18 - RMSP. (Parra et al., 2021)	78%	-	-	-	-
ResNet18 - Adam (Parra et al., 2021)	90%	-	-	-	-

O método proposto mostrou que apesar das dificuldades que surgiram no desenvolvimento do trabalho, como uma base de dados consideravelmente pequena e dados difíceis de padronizar, foi possível obter bons resultados na classificação de imagens de fundo de retina para detecção da toxoplasmose ocular, utilizando algoritmos de classificação.

Uma das vantagens do método proposto em comparação com Parra et al. (2021a) e Alam et al. (2023) é a falta de necessidade de realizar *data augmentation*. Parra et al. (2021a) e Parra et al. (2021b) implementaram a técnica de aprendizado por transferência em seus modelos, outra técnica que não foi necessária na implementação do presente trabalho. Outra vantagem da combinação de algoritmos de classificação e características radiômicas sobre as CNNs é que essa combinação é computacionalmente menos intensa, ou seja, foram utilizados menos recursos computacionais.

As limitações deste estudo estão relacionadas diretamente com a base de dados consideravelmente pequena e na dificuldade em encontrar bases de dados públicas contendo imagens da toxoplasmose ocular.


Quando se trata da aplicabilidade clínica, o método proposto pode servir como ferramenta auxiliar para um oftalmologista na detecção da toxoplasmose ocular, em condição de altas pontuações na classificação, uma vez que as feridas podem passar despercebidas. Com o auxílio do método implementado, o diagnóstico precoce da doença pode ser feito e o paciente pode ser tratado, dado que caso a doença não seja tratada adequadamente, pode levar à cegueira.

CONCLUSÃO

A toxoplasmose ocular possui um diagnóstico complicado, devido aos diferentes formatos e posições das feridas na retina, o que pode dificultar a detecção da doença. Um diagnóstico rápido e preciso é essencial para indicar o tratamento ideal para a doença, evitando suas complicações, como perda da visão e cegueira.

Diante desses fatos, neste artigo foi desenvolvido um método de classificação utilizando métodos tradicionais de visão computacional combinados com técnicas de processamento de imagens. As características radiômicas extraídas se mostraram bastante eficientes, uma vez que os modelos de classificação, em sua maioria, obtiveram uma pontuação acima de 90% em todas as métricas, o que é considerado ótimo.

Com os resultados obtidos, foi notável que o presente trabalho pode contribuir para auxiliar em um diagnóstico de baixo custo computacional, rápido e automático da toxoplasmose ocular. A vantagem na



detecção automática da doença a partir das imagens médicas pode implicar no auxílio para a detecção e tratamento, evitando suas complicações.

Espera-se, em trabalhos futuros, a implementação do método proposto em serviços oferecidos à rede de saúde, implementando o método criado em um sistema de auxílio ao diagnóstico, atuando como uma ferramenta auxiliar para oftalmologistas na interpretação dos exames de fundo de olho.

AGRADECIMENTOS

FNDE (Programa de Educação Tutorial).

REFERÊNCIAS

- Alam, S. S. et al. Benchmarking Deep Learning Frameworks for Automated Diagnosis of Ocular Toxoplasmosis: A Comprehensive Approach to Classification and Segmentation. 2023. Disponível em: <<https://arxiv.org/pdf/2305.10975>>. Acesso em: 27 dez 2023.
- Baffa, M. et al. Radiomic-based features for diabetic retinopathy early detection using deep neural networks. 2022. Disponível em: <https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4168544>. Acesso em: 12 jan 2024.
- Bonametti, A. M. et al. Surto de toxoplasmose aguda transmitida através da ingestão de carne crua de gado ovino. Revista Sociedade Brasileira de Medicina Tropical, v. 30, p. 21–25, 1997. Disponível em: <<https://www.scielo.br/j/rsbmt/a/GGkpmrtpZgVRkce5nbYpWFB/>>. Acesso em: 15 dez 2023.
- Chakravarthy, A. D. et al. An approach towards automatic detection of toxoplasmosis using fundus images. In: 2019 IEEE 19th International Conference on Bioinformatics and Bioengineering (BIBE). [S.l.: s.n.], 2019. p. 710–717. Disponível em: <https://www.researchgate.net/publication/338374743_An_Approach_Towards_Automatic_Detection_of_Toxoplasmosis_using_Fundus_Images>. Acesso em: 29 dez 2023.
- Dias, R. A. F.; Freire, R. L. Surtos de toxoplasmose em seres humanos e animais. Semina: Ciências Agrárias, v. 6, p. 239–248, 2005. Disponível em: <<https://www.redalyc.org/pdf/4457/445744076015.pdf>>. Acesso em: 18 dez 2023.
- Hospital de Olhos de Sergipe. Toxoplasmose. 2017. Disponível em: <<https://www.hosergipe.com.br/blog/toxoplasmose/>>. Acesso em: 10 dez 2023.
- Kim, S. J.; Cho, K. J.; Oh, S.. Development of machine learning models for diagnosis of glaucoma. PLOS ONE, v. 12, n. 5, p. e0177726, 2017. Disponível em: <<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0177726>>. Acesso em: 08 out 2024.

- Maresh, B. Machine Learning Algorithms - A Review. 2018. Disponível em: <https://www.researchgate.net/profile/Batta-Mahesh/publication/344717762_Machine_Learning_Algorithms_-_A_Review/links/5f8b2365299bf1b53e2d243a/Machine-Learning-Algorithms-A-Review.pdf>. Acesso em 31 jan 2024.

- Microsoft. What is Computer Vision? 2023. Disponível em: <<https://azure.microsoft.com/en-us/resources/cloud-computing-dictionary/whatis-computer-vision/object-classification>>. Acesso em: 05 set 2024.

- Nogueira, V.; Liverani, M. Toxoplasmose Ocular. 2014. Disponível em: <<https://revistas.rcaap.pt/oftalmologia/article/view/6848/5124>>. Acesso em: 10 dez 2023.

- Parra, R. et al. A trust-based methodology to evaluate deep learning models for automatic diagnosis of ocular toxoplasmosis from fundus images. Diagnostics, v. 11, n. 11, 2021. Disponível em: <<https://www.mdpi.com/2075-4418/11/11/1951>>. Acesso em: 13 jan 2024.

- Rizzo, S. et al. Radiomics: the facts and the challenges of image analysis. European Radiology Experimental, v. 2, n. 1, p. 36, 2018. Disponível em: <<https://doi.org/10.1186/s41747-018-0068-z>>. Acesso em: 10 jan 2024.

- Santos, C. A. P. d.; Conceição, L. L. d. Percepção de gestantes sobre a incidência da toxoplasmose, barreiras – BA. 2018. Disponível em: <<https://www.periodicos.unc.br/index.php/sma/article/view/1761/885>>. Acesso em: 15 fev 2024.

- Tavares, Aline. Toxoplasmose: doença é transmitida por água e alimentos contaminados; casos graves podem causar perda de visão e danos cerebrais. Butantan, 2024. Disponível em: <<https://butantan.gov.br/noticias/toxoplasmose-doenca-a-e-transmitida-por-agua-e-alimentos-contaminados--casos-graves-podem-causar-perda-de-visao-e-danos-cerebrais#:~:text=No%20Brasil%2C%20a%20toxoplasmose%20atinge,foram%2040%20mil%20casos%20registrados>>. Acesso em: 09 out 2024.

- Shinzato Oftalmologia. Toxoplasmose pode levar a cegueira. 2016. Disponível em: <<https://shinzatooftalmologia.com.br/toxoplasmose/>>. Acesso em: 10 dez 2023.